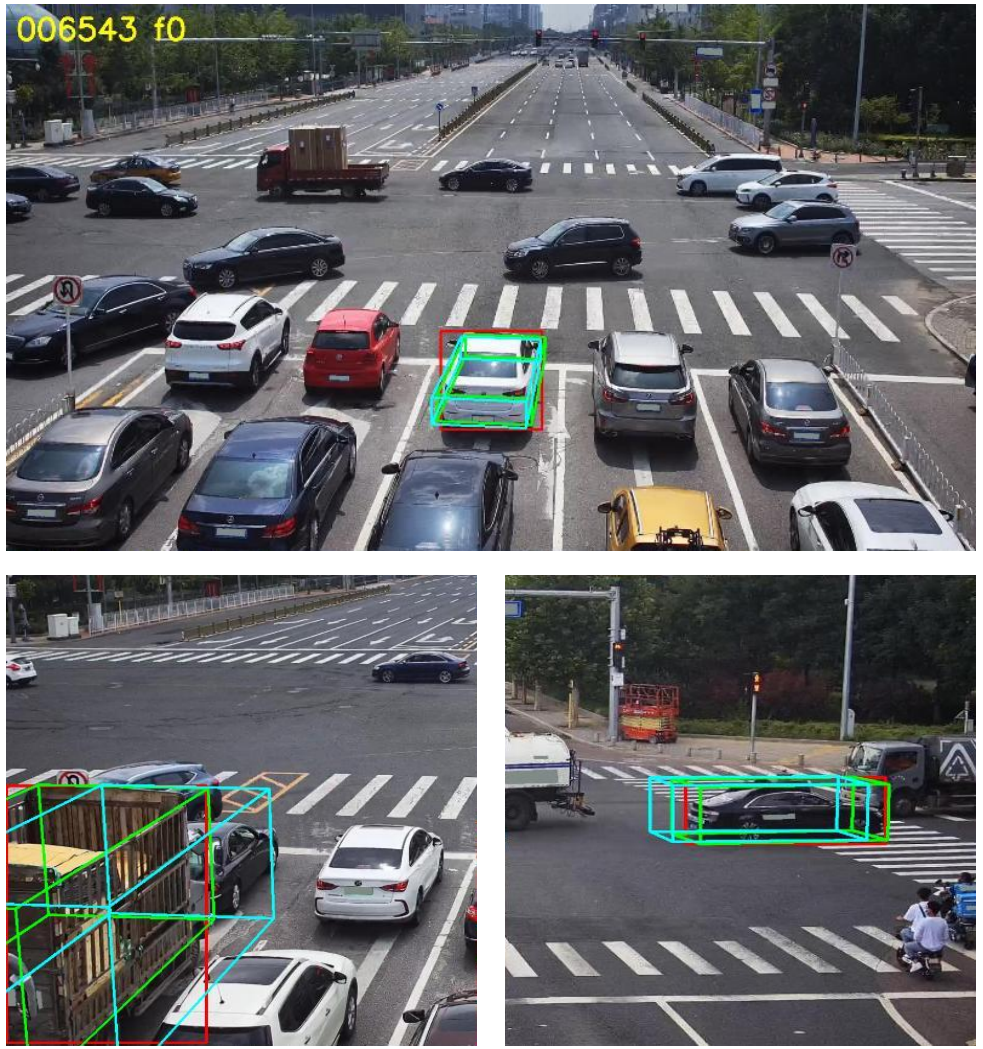
文本约束的几何三维视觉语言跟踪

Tenn-VLSOT-Geo：把描述里的距离、尺寸和航向代入相机几何，用截断感知的 3D 框投影拟合给出每帧中心

平台测试 SR@0.5	平台测试 ACE	5 折交叉验证 SR@0.5
61.67	**0.226 m**	**88.41**
排行榜第 3 / 14	非零成绩方法中最低	227 段训练片段

望远队　数据科学与人工智能研究院　指导老师：孙士杰

队长：滕恒基　成员：滕恒基、梁天宇、苗富敬、刘帅、安子茜



测试集样例。红：选中的检测框　绿：预测 3D 框投影　青：v11c 射线法

代码：github.com/Teng10099/VLSOT-2026-Wangyuan-Geo（Apache-2.0）　数据：TRAIN 227 段 / TEST 10 段，每段 30 帧

方法概述：文本约束的几何流水线

不训练三维网络：先选对目标，再用文本给出的度量信息把 2D 框解成 3D 框

输入

30 帧单目图像 1920×1080
英文描述 + 颜色/状态/类别字段
相机标定（V2X-Seq-SPD）

① 文本解析

尺寸 l/w/h；第 0/14/29 帧距离
航向与朝向词、九宫格区域、名次
截断、最近车及其相对方位

② 二维检测

YOLO11x（COCO 预训练）
置信度 ≥0.05 的车辆框都作候选
EFN 分类器给出颜色概率

③ 候选打分

9 个特征：距离一致、区域、
名次、颜色、类别、截断、方位…
线性排序模型（TRAIN 拟合）

④ 全局跟踪

Viterbi 动态规划选整条轨迹
相邻帧框连续
运动方向与文本航向一致

⑤ boxfit 三维定位

文本尺寸 + 航向 + 距离
3D 框投影对齐检测框未截断边
地平面作为高度弱先验

⑥ 时序平滑

停车：30 帧取中位数
运动：保持文本距离曲线
方位角做局部线性平滑

输出

每帧 l w h x y z
virtuallidar 坐标系
result/<视频ID>.txt

学到的参数很少：打分权重 9 个、地平面 3 个、框中心偏移 2 个、boxfit 边噪声 4 个，只用 TRAIN 标签拟合

与端到端网络的区别：距离、尺寸、航向直接代入几何求解，选择和定位两步的误差可以分开度量

核心创新点

1 文本度量约束取代单目深度估计

· 描述给出第 0/14/29 帧距离（0.1 m 精度）与尺寸：中心落在文本距离上，深度不靠图像猜

· 运动目标保持文本距离曲线、只平滑方位角，消除滑动平均在首尾帧约 0.45 m 的偏差

结果：平台 ACE 2.53 m → 0.226 m

2 复刻数据生成规则的跨模态匹配

· 按数据集描述生成脚本计算九宫格区域、同格名次（格角到框底边中点距离）、最近车方位（3.7 m 阈值）

· 颜色用作者打标签时的同款 EFN 分类器；9 个特征 + 线性排序 + Viterbi 全局轨迹

结果：交叉验证 SR@0.5 77.78 → 81.70

3 截断感知的 3D 框投影拟合（boxfit）

· 已知文本尺寸与航向，求中心使 3D 框投影外接矩形对齐检测框；离图像边界 10 px 内的边不参与

· 近处截断目标的 2D 框中心不是 3D 中心的投影，沿框中心射线取文本距离会把中心放偏

结果：近处截断片段 SR@0.5 9.6% → 61.8%

4 评测口径反推与同口径验证

· v9→v11c 只改 1 段，ACE 降 0.369，超过“角点”口径上限 0.27 → 平台用真实 3D IoU；PR 阈值为 0.1/0.05 m

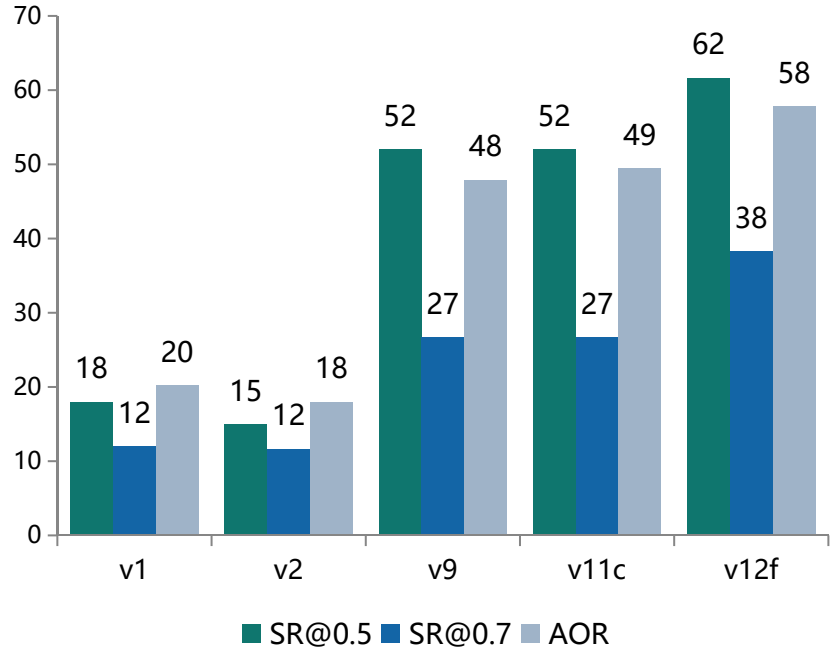
· 按目标分组 5 折交叉验证；修正训练 GT 与检测框的匹配（原方法 13% 的帧配到邻车）

结果：v11c → v12f：CV +6.71，平台 SR@0.5 +9.67

实验结果与消融

左：5 折交叉验证（227 段 TRAIN，按目标分组，真实 3D IoU）；右：平台测试集 5 次提交

配置	SR@0.5	SR@0.7	AOR	ACE/m	误差 <0.1m
v9 基线：YOLO11x + CLIP 颜色 + 射线定位	77.78	52.63	60.95	0.684	21.31
+ 复刻生成规则的名次/最近车方位、距离死区	80.41	55.24	63.23	0.558	23.32
+ EFN 颜色、名次框距上限（v11c）	81.70	56.49	64.17	0.566	23.99
+ 训练 GT↔检测框按投影矩形匹配	81.69	57.50	64.40	0.589	24.70
+ 运动目标方位角局部线性平滑	82.07	58.56	64.73	0.577	25.80
+ boxfit（仅截断框，边距 4 px）	83.19	58.94	65.81	0.550	25.89
+ boxfit（仅截断框，边距 10 px）	87.46	60.57	67.83	0.515	25.93
+ boxfit（全部帧）	87.78	68.66	70.35	0.496	36.98
+ 二次距离插值、高度先验放宽（v12f）	**88.41**	**69.16**	**70.57**	**0.498**	**38.63**



平台 ACE（m）： 2.53 → 2.84 → 0.77 → 0.40 → 0.23

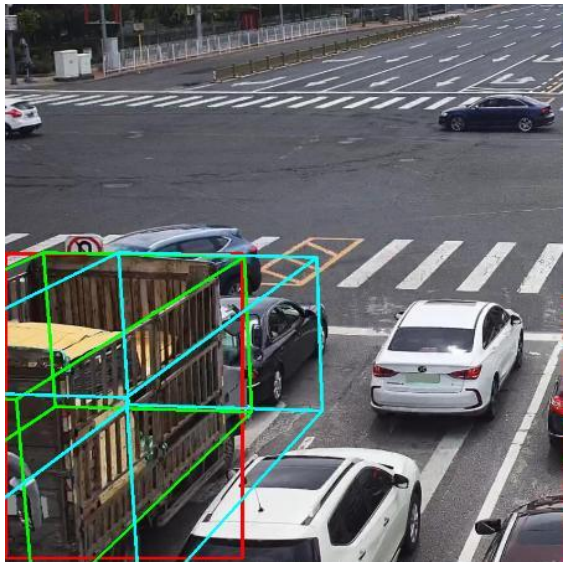
v11c → v12f: SR@0.5 +9.7　SR@0.7 +11.7　AOR +8.4

PR@1.0 10.33 → 16.67　PR@0.5 3.00 → 1.67

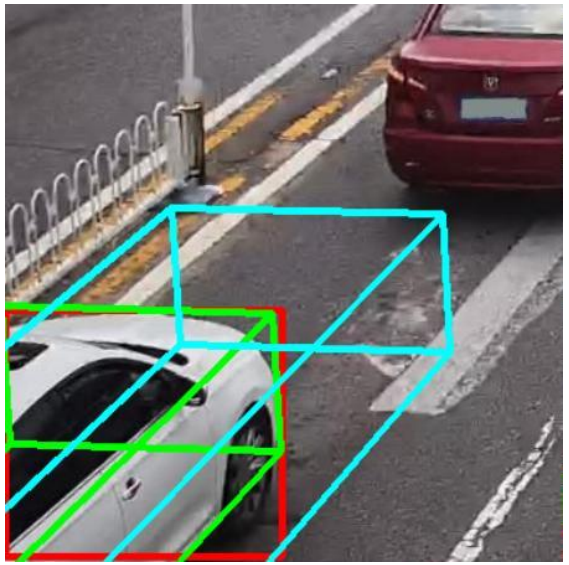
试过但未采用（CV SR@0.5，相对 v12f）： 按机位校正系统偏差 −4.07；匀速轨迹拟合 −2.6；射线与 boxfit 加权混合 −0.04 ~ −0.26；尺寸缩放 ≤ +0.2 但 SR@0.7 下降；残差回归 +0.56 但 PR@1.0 −0.7

测试样例与误差分析

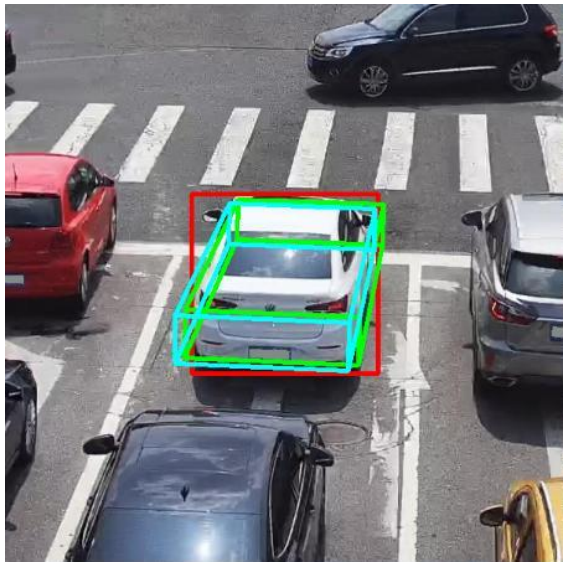
红：选中的检测框　绿：v12f 预测 3D 框投影　青：v11c 射线法（同一选择，只换三维定位）



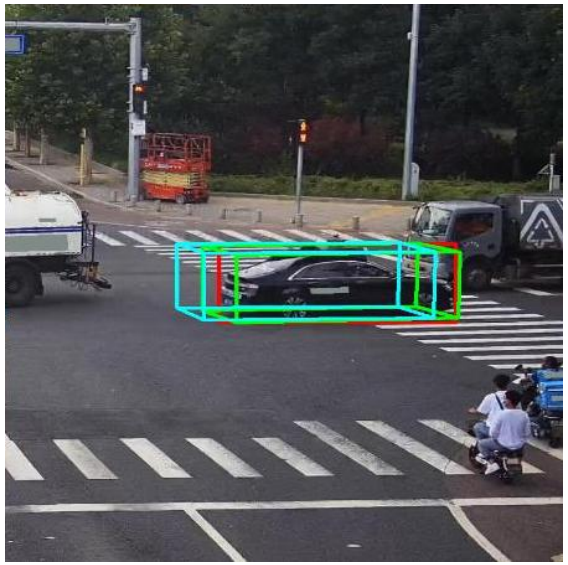
003235 截断货车：绿框贴合可见的上边和右边



001483 左下角截断：射线法框中心偏上偏右



006543 h=0.6 的扁框：高度误差直接决定 IoU



033447 横穿运动：末帧不再被平滑拖回

误差上限（只用 TRAIN 标签统计）

· 停车目标标注逐帧抖动均值 9 cm：中心误差 <10 cm 的帧最多约 71%，<5 cm 最多约 40%

· 标注尺寸逐帧变化：中心完全正确时 SR@0.7 上限约 95%（停）/ 81%（动）

· 运动目标中间帧距离只能插值：一半帧径向误差 >0.1 m

局限与下一步

· 测试集难例集中：两个左下角截断的近处目标（约 15 m）、两个约 100 m 远的运动目标

· CV 88.4 与平台 61.7 的差距推测主要来自这些难例（近处截断片段在 TRAIN 中只有 19 / 227 段）；平台不给逐段成绩，无法逐段核实

· 计划：检测框测试时增强精修框边、远处目标亚像素定位、整段轨迹联合优化